

YOLOv8 Tabanlı Otomatik Sıçan ve Deney Alan Tespiti: Hayvan Deneyleri için Nesne Algılama ve Yöntemler

1st Emre Sevindi
Computer Engineering
Antalya, Türkiye
emre.sevindi@ogr.ksbu.edu.tr

Abstract—Bu çalışma, hayvan deneylerinde kaydedilen görüntülerden sıçanların otomatik tespiti için geliştirilmiş bir YOLOv8 tabanlı yöntemi ele almaktadır. Bu yöntem, deney ortamlarındaki sıçanları tespit etmek ve konum bilgilerini bulmak amacıyla kullanılmaktadır. YOLOv8 modeli, nesne algılama ve nesnelerin bulundukları alanların konum bilgilerini sağlayabilen bir model olarak öne çıkmaktadır. Çalışmanın temeli, video görüntülerini içeren bir veri setinin Roboflow aracılığıyla etiketlenmesi ve işlenmesine dayanmaktadır. Hassasiyetle etiketlenmiş veriler, YOLOv8 modelinin eğitiminde kullanılmış ve oluşturulan model, düşük ışık koşulları da dahil olmak üzere sıçanları tanıma konusunda etkili bir performans sergilemektedir.

Deney görüntüleri kaydı esnasında ortam ışığının zayıf ya da dengesiz olduğu durumlarda modelin doğru bir şekilde sıçan tespiti yapabilmesini sağlamak için histogram eşitleme yöntemi uygulanmıştır. Ayrıca, araştırmada, deney ortamının uzamsal yapısını ve sıçanların yerleşimlerinin belirlenmesi amacıyla ikincil bir model geliştirilmiştir. Geliştirilen bu iki model ile sadece sıçanları tanımlamakla kalmayıp, aynı zamanda onların deney düzeneği içerisindeki konumlarını analiz etme imkanı elde edilmiştir.

Oluşturulan yöntemin sıçan ve deney alanlarının tespitinde etkili olduğu görülmektedir. Modelin entegrasyonu, laboratuvar deneylerinin daha verimli ve doğru bir şekilde yürütülmesine olanak tanırken, deney hayvanlarının takip ve süreçlerini kolaylaştırmaktadır.

Çalışmada, YOLOv8 tabanlı geliştirilen yöntem sayesinde deney görüntülerinden sıçanların tespit edilmesi ve elde edilen veriler kullanılarak daha derinlemesine analiz yapılabilir.

Çalışmada ayrıca davranışsal değerlendirilmelerin yapılması amacıyla, sıçanların deney alanlarında hareketlerini, hızlarını ve olası etkileşimlerini izlemek için ısı haritaları oluşturulmuştur. Bu sayede, sıçan davranışları daha net görülebilmektedir. Bu veriler ışığında elde edilen veriler ile deney sonuçları değerlendirilmiştir. Bu yaklaşım, hayvan davranışlarına dair detaylı veri setlerinin toplanması ve değerlendirilmesi konusunda yeni bir perspektif sunarak, literatüre katkı sağlayacaktır.

Keywords— *Sıçan Tespiti, YoloV8, Düşük Işık Sıçan Tespiti, Deney Alanı Tespiti*

I. Giriş

Biyomedikal araştırmalarda, hayvan deneyleri sıçanların davranışlarını sistemli bir şekilde gözlemlemeyi ve analiz etmeyi gerektirmektedir. Bu bağlamda, mevcut çalışma, YOLOv8 (Khare, Gandhi, Rahalkar, & Mane, 2023) temelli bir yöntemi ele almaktadır, bu yöntem sıçanların

otomatik tespiti için geliştirilmiş olup, deney ortamlarındaki sıçanları tanımlamak ve konum bilgilerini elde etmek amacıyla kullanılmaktadır. YOLOv8 modeli, biyomedikal araştırmalarda hayati öneme sahip olan hayvan davranışlarının detaylı bir şekilde incelenmesine olanak sağlamaktadır.

Bu çalışmanın temelini, video görüntülerini içeren bir veri setinin titiz bir etiketleme ve işleme süreci oluşturmaktadır. Roboflow (Roboflow, 2023) aracılığıyla gerçekleştirilen bu işlem, YOLOv8 modelinin eğitiminde kullanılarak sıçanların tanımlanmasını sağlamaktadır. Model, zorlu koşullarda dahi, özellikle düşük ışık şartlarında, etkili bir performans sergilemektedir.

Deney görüntülerinin çekildiği anlarda ortam ışığının düşük veya dengesiz olduğu durumlar için, modelin doğru bir şekilde sıçan tespiti yapabilmesini temin etmek amacıyla histogram eşitleme yöntemi uygulanmıştır. Bu teknik, görüntüdeki ışık dağılımını iyileştirerek modelin genel performansını artırmaktadır.

Ek olarak, sıçanların yerleşim yerlerini belirlemek amacıyla ikincil bir model geliştirilmiştir. Bu ikincil model, deney ortamının uzamsal yapısını analiz ederek sıçanların konumlarına dair daha ayrıntılı bilgiler sunmaktadır.

Geliştirilen yöntem, sadece sıçanları tanımlamakla kalmayıp, aynı zamanda onların deney düzeneği içerisindeki konumlarını analiz etme imkanı sağlamaktadır. Bu, laboratuvar deneylerinin daha kapsamlı ve anlamlı bir şekilde gerçekleştirilmesine katkıda bulunmaktadır.

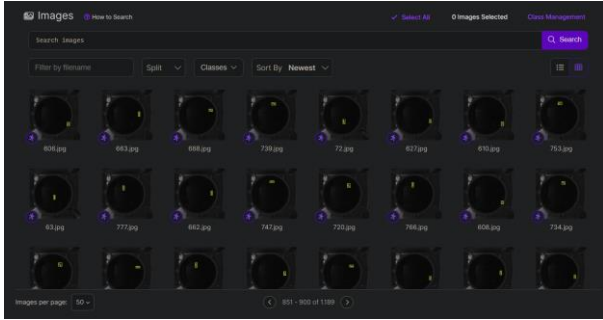
Çalışmada ayrıca, sıçan davranışlarını daha ayrıntılı bir şekilde değerlendirmek amacıyla ısı haritaları oluşturulmuştur. Bu veriler, deney sonuçlarının daha derinlemesine analiz edilmesine olanak tanımaktadır.

II. Veri Setinin Oluşturulması

Bu araştırmanın temelini oluşturan veri seti, hayvan davranışlarının detaylı bir şekilde incelenmesi amacıyla deney alanındaki videolardaki karelerdeki farelerin etiketlenmesi ve hazırlanması sürecini içermektedir. Etiketleme işlemi büyük bir özenle gerçekleştirilmiş olup, toplamda 4878 adet etiketlenmiştir.

Veri seti, farklı deneylerin uygulandığı çeşitli bağlamlarda elde edilen videoların kullanılmasıyla zenginleştirilmiştir.

Morris Water Maze (Morris, 2008), Elevated Plus Maze (Komada, Takao, & Miyakawa, 2008), Novel Object Recognition (Antunes & Biala, 2012), Maternal Separation (Uhelski & Fuchs, 2010) gibi önemli deneylerin videoları, bu veri setinin oluşturulmasında temel kaynaklar olmuştur.



Veri seti, farklı deneylerin uygulandığı çeşitli bağlamlarda elde edilen videoların kullanılmasıyla zenginleştirilmiştir. Morris Water Maze, Elevated Plus Maze, Novel Object Recognition, Maternal Separation gibi önemli deneylerin videoları, bu veri setinin oluşturulmasında temel kaynaklar olmuştur.

Bu etiketlenmiş resim verileri, özellikle yapay zeka modelinin eğitimi açısından büyük bir değer taşımaktadır. Model, bu zengin ve çeşitli veri seti üzerinde eğitilerek, farelerin çeşitli davranışsal tepkilerinin incelenmesinde yüksek hassasiyet ve doğruluk seviyeleri sağlamaktadır. Elde edilen bu veri seti, biyomedikal araştırmalarda hayvan davranışlarının daha derinlemesine anlaşılmasına katkıda bulunmak üzere özenle oluşturulmuştur.

III. Modelin Yapısı

Bu çalışmada kullanılan YOLOv8 modeli, transfer learning (Weiss, Khoshgoftaar, & Wang, 2016) yaklaşımıyla özelleştirilmiştir. Toplamda 225 katman içeren bu modelin detayları şu şekildedir:

Modelin evre 0-9 arasında kullanılan Convolutional (O'Shea & Nash, 2015) ve C2f katmanları, giriş verisinin daha yüksek seviyeli özelliklere dönüştürülmesine katkı sağlar. Evre 10-14'te ise Spatial Pyramid Pooling (SPPF) (He, Zhang, Ren, & Sun, 2014) ve Upsampling (Kundu, Mostafa, Sridhar, & Sundaresan, 2020) katmanları, özellik haritalarının daha geniş bir bağlam içinde ele alınmasına yardımcı olur.

Evre 15-22 arasındaki Concat ve Detect katmanları, farklı özellik haritalarını birleştirerek nesne tespiti için kullanılır. Bu katmanlar, YOLO algoritmasının temelini oluşturur.

Toplamda 11,135,987 parametreye sahip olan bu model, önceden eğitilmiş ağırlıkların transferi ile özelleştirilmiştir. Eğitim sürecinde SGD optimizyer ve özelleştirilmiş bir öğrenme oranı ($\text{lr}=0.01$) kullanılmıştır.

	from	n	params	module	arguments
0	-1	1	928	ultralytics.nn.modules.Conv	[3, 32, 3, 2]
1	-1	1	18568	ultralytics.nn.modules.Conv	[32, 64, 3, 2]
2	-1	1	29056	ultralytics.nn.modules.C2f	[64, 64, 1, True]
3	-1	1	73984	ultralytics.nn.modules.Conv	[64, 128, 3, 2]
4	-1	2	197632	ultralytics.nn.modules.C2f	[128, 128, 2, True]
5	-1	1	295424	ultralytics.nn.modules.Conv	[128, 256, 3, 2]
6	-1	2	788488	ultralytics.nn.modules.C2f	[256, 256, 2, True]
7	-1	1	1188672	ultralytics.nn.modules.C2f	[256, 512, 3, 2]
8	-1	1	1838888	ultralytics.nn.modules.C2f	[512, 512, 1, True]
9	-1	1	656896	ultralytics.nn.modules.SPPF	[512, 512, 5]
10	-1	1	0	torch.nn.modules.upsampling.Upsample	[None, 2, 'nearest']
11	[-1, 6]	1	0	ultralytics.nn.modules.Concat	[1]
12	-1	1	591368	ultralytics.nn.modules.C2f	[768, 256, 1]
13	-1	1	0	torch.nn.modules.upsampling.Upsample	[None, 2, 'nearest']
14	[-1, 4]	1	0	ultralytics.nn.modules.Concat	[1]
15	-1	1	148224	ultralytics.nn.modules.C2f	[384, 128, 1]
16	-1	1	147712	ultralytics.nn.modules.Conv	[128, 128, 3, 2]
17	[-1, 12]	1	0	ultralytics.nn.modules.Concat	[1]
18	-1	1	493856	ultralytics.nn.modules.C2f	[384, 256, 1]
19	-1	1	598336	ultralytics.nn.modules.Conv	[256, 256, 3, 2]
20	[-1, 9]	1	0	ultralytics.nn.modules.Concat	[1]
21	-1	1	1969152	ultralytics.nn.modules.C2f	[768, 512, 1]
22	[15, 18, 21]	1	2116435	ultralytics.nn.modules.Detect	[1, [128, 256, 512]]

Model summary: 225 layers, 11135987 parameters, 11135971 gradients, 28.6 GFLOPs

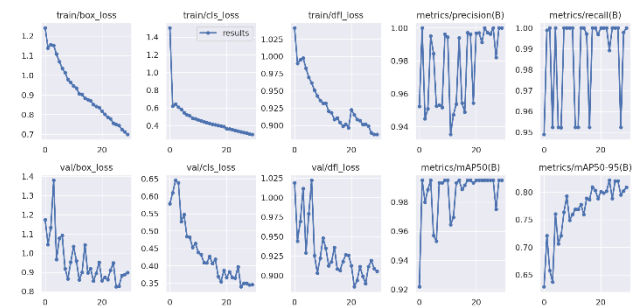
IV. Modelin Eğitimi

Bu araştırma kapsamında YOLOv8 modeli, toplamda 30 epoch süresince eğitildi. Eğitim süreci, özellikle GPU bellek kullanımının gözetiminde gerçekleştirildi ve bu süreçte bellek kullanımının 6.55G seviyelerine ulaştığı gözlemlendi.

Eğitim veri seti, deney alanındaki videolardan elde edilen karelerdeki farelerin özenle etiketlenmesiyle oluşturuldu. Toplamda 4878 etiketlenmiş eğitim resmi bu süreçte kullanıldı. Her bir eğitim resmi, modelin nesne algılama yeteneklerini geliştirmek için titizlikle seçildi.

Modelin eğitimi sırasında, epoch bazlı eğitim istatistikleri şu şekildedir: box_loss değeri 0.6991, cls_loss değeri 0.2995, ve dfl_loss değeri 0.8869. Bu değerler, modelin nesne algılama konusundaki başarı düzeyini yansıtmaktadır.

Eğitim sonuçlarına paralel olarak, modelin performansının doğrulama veri seti üzerindeki değerlendirmesi de gerçekleştirildi. Doğrulama sonuçları, tüm sınıflar için Precision (P), Recall (R), mAP50, ve mAP50-95 metriklerini içerir. Bu metriklerin değerleri sırasıyla şu şekildedir: 1, 0.989, 0.995, ve 0.81. Bu değerler, modelin nesne tespiti konusundaki başarısını nicel olarak ifade etmektedir.



Son olarak, modelin işlem hızı üzerine yapılan değerlendirmeler, her bir görüntü için 3.3ms ön işleme süresi, 20.6ms çıkarım süresi, 0.1ms kayıp hesaplama süresi, ve 8.9ms son işleme süresini ortaya koymaktadır. Bu değerler, modelin işlem süreçlerini ayrıntılı bir şekilde analiz etmemize olanak tanıırken, elde edilen sonuçların güvenilirliğini vurgulamaktadır.




V. Morris Su Labirenti Deneyi ve Koordinat Tahmini

Morris Water Maze deneyi, farelerin belirli bir suda gizlenmiş platformu bulmalarını gerektiren bir görevdir. Bu deneyde elde edilen fare konum verileri, derin öğrenme modeli tarafından eğitilerek farelerin gelecekteki konumlarını tahmin etmek amacıyla kullanıldı. Model, LSTM (Uzun Kısa Süreli Bellek) (Breuel, 2015) ve yoğun katmanlardan oluşan bir sinir ağı mimarisi üzerine kuruldu ve eğitim sürecinde kayıp fonksiyonu olarak ortalama karesel hata kullanıldı.

Eğitim öncesi, farelerin geçmiş konum verileri normalize edildi ve ardından eğitim ve test veri setlerine ayrıldı. Eğitim sürecinde, modelin performansını değerlendirmek için ortalama karesel hata kullanılarak kayıp değerleri izlendi. Model, eğitim veri seti üzerinde 10 epoch boyunca eğitildi ve her bir epoch sonunda doğrulama veri seti üzerindeki kayıp değerleri değerlendirildi.

Eğitim sonrasında, model test veri seti üzerinde değerlendirildi ve ortalama karesel hata ölçümü kullanılarak tahmin performansı ölçüldü. Modelin genel başarı gösterdiği görüldü, test veri seti üzerinde elde edilen kayıp değeri 0.0005.



Bu çalışma, Morris Water Maze deneyinden elde edilen sayısal verilerin derin öğrenme modeli tarafından başarılı bir şekilde işlenerek farelerin gelecekteki konumlarını

tahmin etmede etkili bir araç olarak kullanılabileceğini göstermektedir.

```
test_x[i]: array([[0.9052571, 0.90530086, 0.90262057, 0.90070872, 0.89890861,
0.89876616, 0.89799082, 0.89619483, 0.89716115, 0.89703803],
[0.22972726, 0.22991085, 0.22592489, 0.22261513, 0.22133722,
0.22287554, 0.22111876, 0.2202227, 0.21831589, 0.21751939]])
test_y[i]: array([[0.89137326, 0.21106942],
[0.8903186, 0.21034717]])
predictions[i]: array([[0.8924327, 0.21631145],
[0.88201946, 0.22564593]], dtype=float32)
```

VI. BAŞVURULAR

- Antunes, M., & Biala, G. (2012). The novel object recognition memory: neurobiology, test procedure, and its modifications. *Cognitive Processing*.
- Breuel, T. M. (2015). Benchmarking of LSTM networks. *arXiv preprint arXiv:1508.02774*.
- He, K., Zhang, X., Ren, S., & Sun, J. (2014). Spatial pyramid pooling in deep convolutional networks for visual recognition. *arXiv preprint arXiv:1406.4729*.
- Khare, O. M., Gandhi, S., Rahalkar, A. M., & Mane, S. (2023). YOLOv8-Based Visual Detection of Road Hazards: Potholes, Sewer Covers, and Manholes. *arXiv preprint arXiv:2311.00073*.
- Komada, M., Takao, K., & Miyakawa, T. (2008). Elevated plus maze for mice. *JoVE (Journal of Visualized Experiments)*.
- Kundu, S., Mostafa, H., Sridhar, S. N., & Sundaresan, S. (2020). Attention-based image upsampling. *arXiv preprint arXiv:2012.09904*.
- Morris, R. G. (2008). Morris water maze. *Scholarpedia*.
- O'Shea, K., & Nash, R. (2015). An introduction to convolutional neural networks. *arXiv preprint arXiv:1511.08458*.
- Roboflow. (2023). Roboflow: <https://roboflow.com/> adresinden alındı
- Uhelski, M. L., & Fuchs, P. N. (2010). Maternal separation stress leads to enhanced emotional responses to noxious stimuli in adult rats. *Behavioural brain research*.
- Weiss, K., Khoshgoftaar, T. M., & Wang, D. (2016). A survey of transfer learning. *Journal of Big data*.